

一、任务介绍

研究不同提示策略在分类、抽取、推理等小任务上的效果与代价（准确率、成本、时延），并尝试用 DSPy 等工具做自动提示或程序化提示优化。

二、任务要求

基础：选择 2 - 3 个子任务，系统对比不同提示策略；记录每类策略的性能与推理成本。

进阶：使用 DSPy 做提示/模块自动化搜索，或用 LM-Eval-Harness 统一评测多任务；加入自一致性采样与多数投票。

Demo：交互页面可切换提示策略，展示预测、思维过程摘要与耗时。

三、数据与环境

设备建议：CPU 可行，GPU 更快；Python 3.10+。

工具建议：DSPy（程序化提示与自动化搜索）；LM-Eval-Harness（统一评测）

四、参考文献

[Large Language Models are Zero-Shot Reasoners \(Chain-of-Thought\)](#)

[Self-Consistency Improves Chain-of-Thought Reasoning](#)

五、示例代码仓库

[DSPy](#)

[LM-Eval-Harness](#)